具身智能综合综述（中文翻译）

原标题：Aligning Cyber Space with Physical World: A Comprehensive Survey on Embodied AI **中文译名**：对齐网络空间与物理世界：具身智能综合综述

作者：Yang Liu, Weixing Chen, Yongjie Bai, Xiaodan Liang, Guanbin Li, Wen Gao, Liang Lin（中山大学计算机科学与工程学院 + 鹏城实验室 + 北京大学）

发表：IEEE/ASME Transactions on Mechatronics（机电一体化汇刊） **arXiv**：2407.06886v8（2025-08-25）

翻译说明：本文是全文正文的中文翻译，参考文献部分保留英文（见原 PDF）。术语采用学界通行译法：Embodied AI＝具身智能，World Model＝世界模型，Multi-modal Large Model(MLM)＝多模态大模型，sim-to-real＝仿真到真实（虚实迁移）。

摘要

具身人工智能（Embodied AI）对于实现通用人工智能（AGI）至关重要，并且是众多应用（例如智能机电系统、智能制造）的基础，它连接了网络空间与物理世界。近年来，**多模态大模型（MLMs）** 和 **世界模型（WMs）** 的出现，因其卓越的感知、交互和推理能力而备受关注，使它们成为具身智能体的一种很有前景的架构。

在这篇综述中，我们对具身人工智能的最新进展进行了全面探索。我们的分析首先梳理了具身机器人和仿真器的代表性工作，以充分理解其研究重点和局限性。随后，我们分析了**四个主要研究目标**：

1. **具身感知（Embodied Perception）**
2. **具身交互（Embodied Interaction）**
3. **具身智能体（Embodied Agent）**
4. **仿真到真实迁移（Sim-to-Real Adaptation）**

涵盖最先进的方法、核心范式和全面的数据集。此外，我们探讨了多模态大模型在虚拟和真实具身智能体中的复杂性，强调它们在促进数字和物理环境交互中的重要性。最后，我们总结了具身人工智能的挑战与局限，并讨论了潜在的未来方向。

关键词：具身智能、网络空间、物理世界、多模态大模型、智能体、机电智能

I. 引言

具身人工智能最初源自 Alan Turing 在 1950 年提出的「具身图灵测试（Embodied Turing Test）」[1]，并在机器人、医疗保健和智能制造等应用中得到了广泛发展。

具身人工智能旨在判断：智能体所展现出的智能，是否**不仅仅局限于在虚拟环境（网络空间）中解决抽象问题**，而是**能够应对物理世界的复杂性和不可预测性**。例如，具身人工智能通过将物理组件集成到机电系统中，实现自适应、真实世界的交互，使系统能够自主学习、感知和执行，从而提高效率和功能，如图 1 所示。

- 处于**网络空间**中的智能体，通常被称为**「离身智能」（disembodied AI）**；
- 处于**物理空间**中的智能体，则被称为**「具身智能」（embodied AI）**（见表 I）。

近年来，多模态大模型（MLMs）的进步为具身模型注入了强大的感知、交互和规划能力，从而催生了能够主动与虚拟和物理环境交互的**通用具身智能体和机器人**。因此，具身智能体被广泛认为是多模态大模型的**最佳载体**。近期代表性的具身模型有 **RT-2** [2] 和 **RT-H** [3]。

然而，当前多模态大模型在**长期记忆、理解复杂意图、分解复杂任务**等方面的能力仍然有限。

要迈向通用人工智能（AGI），具身人工智能的发展是一条根本路径。 与 ChatGPT [4] 这类对话式智能体不同，具身人工智能认为：真正的 AGI 必须通过**控制物理躯体（physical embodiments）**、并同时与仿真环境和物理环境交互 [5][6] 才能实现。站在 AGI 驱动创新的最前沿，深入探究具身智能的内涵、厘清其复杂性、评估其当前发展阶段、并展望其未来可能的发展轨迹，显得至关重要。

如今，具身人工智能融合了**计算机视觉（CV）、自然语言处理（NLP）和机器人学**中的多种关键技术，其中最具代表性的是：**具身感知、具身交互、具身智能体，以及仿真到真实的机器人控制** [7]。因此，通过一篇全面的综述来捕捉具身人工智能在通往 AGI 之路上的演进图景，十分必要。

具身智能体是具身智能的核心基础

对于一个具身任务，具身智能体必须能够：

- 充分理解语言指令中的人类意图；
- 主动探索周围环境；
- 全面感知来自虚拟和物理环境的多模态元素；
- 为复杂任务执行恰当的动作 [11][12]。

多模态模型的快速进展，使它们在复杂环境中展现出**优于传统深度强化学习方法的通用性、灵巧性和泛化能力**：

- 来自最先进视觉编码器的预训练视觉表征 [13][14]，提供了对物体类别、姿态和几何的精确估计，使具身模型能够透彻感知复杂动态环境；

- 强大的大语言模型（LLMs）让机器人更好地理解人类的语言指令；
- 前景广阔的多模态大模型（MLMs）为对齐具身机器人的视觉与语言表征提供了可行途径；
- 世界模型（WMs）[15][16] 展现出卓越的仿真能力，以及对物理规律的良好理解，使具身模型能够全面理解物理与真实环境。

这些创新使具身智能体能够全面感知复杂环境、自然与人交互、并可靠地执行任务。

本文的动机与贡献

尽管学界对从多模态大模型中汲取强大感知与推理能力兴趣浓厚，但仍缺少一篇能梳理现有具身智能研究、所面临的挑战以及未来研究方向的综合综述。在多模态大模型时代，我们通过从网络空间到物理世界对具身人工智能进行系统性综述，来填补这一空白。

我们从不同视角展开：**具身机器人、仿真器、四类代表性具身任务（视觉主动感知、具身交互、多模态智能体和仿真到真实迁移），以及未来研究方向。**

与已有工作的区别：虽然已有若干具身人工智能综述 [5][6][17][18]，但其中大多数已过时——它们发表于 2023 年左右才开启的「多模态大模型时代」之前。据我们所知，2023 年后仅有 [6][18] 两篇综述，分别聚焦视觉–语言–动作模型和面向智能制造的具身智能系统。尽管 [18] 首次提出了「AI 大脑 + 身体 + 跨模态传感器」的具身智能架构，但以往综述都未充分考虑多模态大模型、世界模型和具身智能体，也忽略了具身机器人和仿真器的最新进展。

本文的主要贡献有三点：

1. 据我们所知，这是**第一篇**从「基于多模态大模型与世界模型对齐网络空间与物理空间」视角出发的具身智能综合综述，在方法论、基准、挑战和应用方面提供了新的见解；
2. 我们将具身智能归纳为若干关键部分——**机器人、仿真器，以及四大研究任务（具身感知、具身交互、具身智能体、仿真到真实迁移）**，形成一份详尽的具身智能分类体系（taxonomy）；
3. 为促进稳健、通用的具身智能体发展，我们提出了一个新的数据集标准 **ARIO（All Robots In One，万机合一）** 及统一的大规模 ARIO 数据集，涵盖约 **300 万个片段（episodes）**，来自 **258 个系列（series）** 和 **321,064 个任务**。

论文组织结构

- **第 2 章**：介绍具身机器人；
- **第 3 章**：介绍通用和真实场景的具身仿真器；
- **第 4 章**：介绍具身感知（包括主动视觉感知和视觉语言导航）；
- **第 5 章**：介绍具身交互；
- **第 6 章**：介绍具身智能体（包括具身多模态基础模型和具身任务规划）；
- **第 7 章**：介绍仿真到真实迁移（包括具身世界模型、数据收集与训练）；

- **第 8 章**：讨论有前景的研究方向。

II. 具身机器人

具身智能体与物理环境交互，其形态包括机器人、智能家电、自动驾驶汽车等。常见机器人类型如下（见图 2）：

- **固定底座机器人（Fixed-base Robots）**：如 Franka Emika Panda、Kuka iiwa、Sawyer。因其精度高，广泛用于实验室自动化和工业。
- **轮式机器人（Wheeled Robots）**：如 Kiva、Jackal。因结构简单、成本低，在物流和仓储中效率很高；但在崎岖地形上会面临挑战。
- **履带机器人（Tracked Robots）**：如 iRobot PackBot。履带系统在松软地形上提供稳定性，非常适合农业、灾难救援等越野任务。
- **四足机器人（Quadruped Robots）**：如宇树（Unitree）的 A1、Go1，以及波士顿动力（Boston Dynamics）的 Spot。擅长复杂地形探索和救援任务。
- **人形机器人（Humanoid Robots）**：如特斯拉 Optimus。模仿人类的动作和行为以提供个性化服务，灵巧手使其能执行精细任务 [27][28]。结合大语言模型后，这类机器人有望在制造、医疗和服务领域提升效率与安全性。
- **仿生机器人（Biomimetic Robots）**：如鱼形 [32]、昆虫形 [33]、软体机器人 [34]。通过复制自然生物的运动和功能，使其能在复杂环境中作业，并通过模仿生物机制提升能量效率。

III. 具身仿真器

具身仿真器对具身人工智能至关重要，原因在于其**成本效益高、安全性好、可扩展性强、支持快速原型开发、且便于研究获取**。它们能实现受控实验、生成用于训练和评估的数据、并提供标准化基准。为了与环境交互，必须考虑物理特性、物体属性及其相互作用来构建逼真的仿真。本章分两部分介绍常用仿真平台：**基于底层仿真的通用仿真器**，以及**基于真实场景的仿真器**。

A. 通用仿真器（General Simulator）

真实环境中的物理交互和动态变化是不可替代的。然而，将具身模型部署到物理世界往往成本高昂且挑战重重。通用仿真器提供了一个高度贴近物理世界的虚拟环境，可用于算法开发和模型训练，带来显著的成本、时间和安全优势。

- **Isaac Sim**：面向机器人和 AI 研究的高级仿真平台，具备高保真物理仿真、实时光线追踪、丰富的机器人模型库和深度学习支持，应用场景包括自动驾驶、工业自动化和人机交互。

- **Gazebo**：开源机器人仿真器，拥有丰富的机器人库，并与 ROS 紧密集成；支持多种传感器仿真，提供大量预构建的机器人模型和环境，主要用于机器人导航控制及多机器人系统。
- **PyBullet**：Bullet 物理引擎的 Python 接口，使用简单，支持多样的传感器仿真和深度学习集成；支持刚体动力学、碰撞检测和约束求解等实时物理仿真。
- **Genesis**（新推出）：具备**可微物理引擎**和出色的生成能力。

表 II 呈现了 11 个通用仿真器的关键特性和主要应用场景，图 3 展示了它们的可视化效果。

B. 基于真实场景的仿真器（Real-Scene Based Simulators）

在家庭活动中实现通用具身智能体，是具身人工智能的核心目标之一。这类具身智能体需要深入理解人类日常生活，并在室内环境中执行导航、交互等复杂任务。为满足复杂任务的需求，仿真环境必须接近真实世界，这对仿真器的复杂度和真实感提出了很高要求。这类仿真器大多从真实世界采集数据、创建照片级（photorealistic）3D 资产，并使用 UE5、Unity 等 3D 游戏引擎构建场景。丰富逼真的场景使它们成为家庭活动任务的首选。

- **SAPIEN**：专为模拟带关节物体（门、柜、抽屉等）的交互而设计。
- **VirtualHome**：以其独特的「环境图（environment graph）」著称，便于基于自然语言环境描述进行高层具身规划。
- **AI2-THOR**：提供丰富的交互场景，但交互（与 VirtualHome 类似）是基于脚本的，缺乏真实物理交互；这种设计足以应对不需要细粒度交互的具身任务。
- **iGibson 与 TDW**：两者都提供细粒度的具身控制和高度仿真的物理交互。iGibson 擅长提供丰富逼真的大规模场景，适合复杂、长期的移动操作；TDW 则在场景扩展上给用户更大自由度，并具有独特的音频和灵活的流体仿真。
- **Matterport3D**：一个基础的 2D-3D 视觉数据集，在具身智能基准中被广泛使用和扩展。
- **Habitat**：虽然其中的具身智能体缺乏交互能力，但其海量的室内场景、友好的界面和开放的框架，使其在具身导航领域备受推崇。
- **InfiniteWorld**：聚焦统一且可扩展的仿真框架，实现了多项改进、最新的隐式资产重建，以及自然语言驱动的场景生成与编辑；通过分布式协作、AI 辅助和人在回路（Human-in-the-Loop）为复杂机器人交互提供有力支持。

此外，**自动化仿真场景构建**对获取高质量具身数据大有裨益：

- **RoboGen**：通过大语言模型从随机采样的 3D 资产中定制任务，进而创建场景并自动训练智能体；
- **HOLODECK**：能根据人类指令在 AI2-THOR 中自动定制相应的高质量仿真场景；
- **PhyScene**：基于条件扩散（conditional diffusion）生成具有交互性且物理一致的高质量 3D 场景；
- **ProcTHOR**（Allen AI 研究所提出，扩展了 AI2-THOR）：能自动生成具有足够交互性、多样性和合理性的仿真场景。

IV. 具身感知

视觉感知未来发展的「北极星」，是**具身中心的视觉推理**与**社会智能** [59]。

不同于仅仅识别图像中的物体，具备具身感知的智能体必须在物理世界中**移动并与环境交互**。这需要对 3D 空间和动态环境有更深的理解。具身感知要求：视觉感知与推理、理解场景内的 3D 关系，以及基于视觉信息预测并执行复杂任务。

A. 主动视觉感知（Active Visual Perception）

主动视觉感知系统需要**状态估计、场景感知和环境探索**等基本能力。这些能力在 **视觉同步定位与建图（vSLAM）**、**3D 场景理解** 和 **主动探索** 三个领域得到了广泛研究（见图 5、表 III）。

1) 视觉同步定位与建图（vSLAM）

SLAM（同步定位与建图）旨在让机器人在未知环境中确定自身位置的同时构建环境地图 [97]。基于测距的 SLAM [98][99] 依赖激光雷达、雷达、声呐等测距仪生成点云表示，但成本高、环境信息有限。相比之下，**视觉 SLAM（vSLAM）** 使用机载摄像头采集图像帧并构建环境表示，优势在于硬件成本低、小场景精度高、能捕捉丰富的环境细节。

经典 vSLAM 大致分为**传统 vSLAM** 和**语义 vSLAM**：

- **传统 vSLAM**：利用图像数据和多视图几何估计机器人位姿，构建底层地图（稀疏/半稠密/稠密点云），方法包括基于滤波（MonoSLAM）、基于关键帧（ORB-SLAM）、直接跟踪（LSD-SLAM）等。但底层地图不与物体直接对应，机器人难以解读利用。
- **语义 vSLAM**：通过融入语义信息解决了上述局限，增强机器人感知和探索未知环境的能力（如 SLAM++、QuadricSLAM、So-SLAM、SG-SLAM、OVD-SLAM、GS-SLAM）。

2) 3D 场景理解（3D Scene Understanding）

3D 场景理解旨在从 3D 场景数据中**区分物体语义、识别其位置、推断几何属性**，是自动驾驶、机器人导航、人机交互的基础。场景可用 LiDAR 或 RGB-D 传感器记录为 3D 点云。与图像不同，点云是**稀疏、无序、不规则**的。近年基于深度学习的 3D 场景理解方法可分为三类：

- **基于投影（Projection-based）**：将 3D 点投影到多个图像平面，用 2D CNN 提取特征（如 MV3D、PointPillars、MVCNN）；
- **基于体素（Voxel-based）**：将点云转换为规则体素网格以便 3D 卷积（如 VoxNet、SSCNet），部分工作通过稀疏卷积提升效率（如 MinkowskiNet、SSCNs、Embodiedscan）；
- **基于点（Point-based）**：直接处理点云（如 PointNet、PointNet++、PointMLP）。

近年来，为实现模型可扩展性，出现了基于 Transformer（PointTransformer、Swin3d、PT2、3D-VisTA、LEO、PQ3D）和基于 Mamba（PointMamba、Mamba3D）的架构。其中 **PQ3D** 通过无缝融合点云、多视图图像和体素的特征来增强场景理解。

3) 主动探索（Active Exploration）

3D 场景理解方法让机器人能**被动**感知环境，其信息获取和决策是静态的，不随场景变化而调整。因此，被动感知虽必不可少，但必须辅以**主动探索**，使机器人能动态地与环境交互并感知周围（见图 5）。当前方法主要通过**与环境交互** [88][89] 或**改变观察方向**以获取更多视觉信息 [90]–[93]。

例如：Pinto 等人 [88] 提出一种「好奇机器人」，通过与环境的物理交互学习视觉表征，而非仅依赖数据集类别标签；Tatiya 等人 [89] 提出多阶段投影框架，通过学到的探索性交互在不同形态机器人间传递隐式知识；Jayaraman 等人 [90] 提出强化学习方法，让智能体通过降低对环境未观测部分的不确定性来主动获取信息丰富的视觉观测；NeU-NBV [91] 提出无地图规划框架，迭代地摆放 RGB 相机以捕捉未知场景中最具信息量的图像；Hu 等人 [92] 用状态价值函数预测未来状态价值来指导机器人探索；Fan 等人 [93] 将主动识别视为序贯证据收集过程，在证据组合理论下提供逐步的不确定性量化。

B. 视觉语言导航（VLN）

视觉语言导航（Visual Language Navigation, VLN） 是一项核心任务，目标是**在未见过的环境中遵循语言指令进行导航**。VLN 要求机器人理解复杂多样的视觉观测，同时解读不同粒度的指令。输入通常包含两部分：

- **视觉信息**：过去轨迹的视频，或一组历史–当前观测图像；
- **自然语言指令**：智能体需要到达的目标，或需要完成的任务。

智能体需利用以上信息，从候选动作列表中选出一个或一系列动作，可表示为：**Action = M(O, H, I)**，其中 O 为当前观测，H 为历史信息，I 为自然语言指令。

1) 数据集

VLN 中的指令可以是**一系列详细的动作描述、完整描述的目标、粗略描述的任务，甚至只是人类的需求**；要完成的任务可能是单次导航、带交互的导航，或需依次完成的多个导航任务。据此，涌现了众多数据集（见表 IV）：

- **R2R**（基于 Matterport3D）：智能体按逐步指令导航，基于视觉观测选择相邻导航图节点前进，直至到达目标；
- **R4R**：将 R2R 路径扩展为更长轨迹，要求更强的长距离指令–历史对齐能力；
- **VLN-CE**：将 R2R/R4R 扩展到连续环境，智能体可在场景中自由移动；
- **TOUCHDOWN**（基于谷歌街景）：在纽约市街景渲染仿真中按指令导航找指定物体；
- **REVERIE**：要求智能体精确定位远处不可见的、由简洁高层指令指定的目标物体；

- **SOON**：智能体接收由粗到细的长复杂指令，先搜大区域再逐步缩小搜索范围；
- **DDN**：只提供人类需求而不指定明确物体，智能体需在场景中自行导航找物体；
- **ALFRED**（基于 AI2-THOR）：按粗细粒度指令，在交互式环境中完成家务任务；
- **OVMM**：在任意未见环境中抓取物体并放到指定位置，提供基于 Habitat 的仿真及真实世界实现框架；
- **BEHAVIOR-1K**：基于人类需求，包含 1000 个长序列、复杂、依赖技能的日常任务；
- **CVDN**：基于对话历史导航，不确定时可提问求助以决定下一步动作；
- **DialFRED**（ALFRED 的扩展）：允许智能体在导航交互中提问获取帮助。

2) 方法

随着大语言模型（LLM）表现惊人，VLN 取得了长足进步。VLN 方法可分为两大方向：

- **基于记忆理解（Memory-Understanding Based）**：聚焦对环境的感知与理解，以及基于历史观测/轨迹的模型设计，属于「向过去学习」；
- **基于未来预测（Future-Prediction Based）**：更关注对未来状态的建模、预测和理解，属于「向未来学习」。

由于 VLN 可被视为**部分可观测马尔可夫决策过程**（未来观测取决于当前环境与智能体动作），历史信息对导航决策（尤其是长跨度导航）意义重大，因此「基于记忆理解」一直是主流。但「基于未来预测」同样重要——它对环境的本质理解在连续环境 VLN 中价值巨大，尤其随着**世界模型**概念的兴起，正受到越来越多关注。

基于记忆理解的方法：

- **图学习**：将导航过程表示为图，每个时间步智能体获取的信息编码为图节点。如 LVERG（分别编码语言与视觉信息，设计语言-视觉实体关系图）、LM-Nav（目标条件距离函数推断连接、构建导航图，用 LLM 从指令提取地标）；
- **非图的历史建模**：如 HOP（对不同粒度的时间有序信息建模，深度理解历史轨迹与记忆）；
- **环境编码**：如 FILM（用 RGB-D 观测和语义分割逐步构建语义地图）、VER（通过 2D-3D 采样将物理世界量化为结构化 3D 单元）；
- **不同学习范式**：如 CMG（对抗学习，交替模仿学习与探索激励）、GOAT（通过因果学习训练无偏模型）、RCM（目标导向外部奖励 + 指令导向内部奖励的跨模态对齐）、FSTT（引入测试时增强 TTA）；
- **大模型应用**：如 NaviLLM（历史观测序列融入嵌入空间，输入 LLM 微调，多基准 SOTA）、NaVid（改进历史信息编码）、LH-VLN（提出 NavGen 平台 + 多粒度动态记忆 MGDM）。

基于未来预测的方法：

- **图学习**：如 BGBL、ETPNav（设计航点预测器，把连续环境导航迁移为离散环境节点间导航）；

- **环境编码**：如 NvEM（主题模块 + 参考模块做邻居视图融合编码）、HNR（用大规模预训练层次神经辐射表征直接预测未来环境的视觉表征，构建可导航的未来路径树）；
- **强化学习**：如 LookBY（强化预测让预测模块「模仿世界」预测未来状态与奖励）；
- **大模型应用**：如 MiC（让 LLM 直接预测目标及其可能位置，通过提示「想象」构建场景）。

兼顾两者的方法：MCR-Agent（三层动作策略：预测目标、预测像素级掩码、向过去决策学习）、OVLM（让 LLM 预测操作与地标序列，导航中持续更新视觉语言地图）。

V. 具身交互

具身交互指的是智能体在物理或仿真空间中与人类和环境交互的场景。典型的具身交互任务有**具身问答（EQA）** 和**具身抓取（Embodied Grasping）**。

A. 具身问答（Embodied Question Answering, EQA）

EQA 任务要求智能体从**第一人称视角探索环境**，收集回答问题所需的信息。具有自主探索和决策能力的智能体，不仅要考虑采取哪些动作去探索环境，还要判断**何时停止探索**来回答问题。现有工作关注不同类型的问题（见图 7）。

1) 数据集（见表 VI）

- **EQA v1**：第一个 EQA 数据集，基于 SUNCG 合成 3D 室内场景（House3D 仿真器），含位置、颜色、颜色房间、介词四类问题；
- **MT-EQA**：扩展到多物体设置，设计六类问题（比较物体间颜色、距离、大小）；
- **MP3D-EQA**：基于 Matterport3D（MINOS 仿真器），把问答扩展到逼真 3D 环境；
- **IQUAD V1**：基于 AI2-THOR，含存在、计数、空间关系三类问题，要求智能体理解「可供性」（affordance）并与动态环境交互；
- **VideoNavQA**：把视觉推理与导航解耦，智能体访问与探索轨迹对应的视频来答题；
- **SQA3D**：简化为「仅问答」，支持更复杂、知识密集的问题和更大规模的数据收集；
- **K-EQA**：问题含逻辑子句和知识短语，需要先验知识才能回答；
- **OpenEQA**：第一个**开放词汇** EQA 数据集，同时支持情景记忆（EM-EQA）和主动探索（A-EQA）两种设定；
- **HM-EQA**：用 GPT4-V 在 Habitat（HM3D）构建，500 个问题、267 个场景；
- **S-EQA**：用 GPT-4 在 VirtualHome 生成数据，回答需评估一组共识对象与状态，给出「是/否」答案；
- **EXPRESS-Bench**：最大的探索感知 EQA 数据集（777 条探索轨迹、2044 个样本），并提出新的评估指标。

2) 方法

- **神经网络方法**：早期用 CNN + RNN 构建「视觉、语言、导航、回答」四个模块（Das 等人 [138]）。后续工作或改进该架构，或把导航与问答模块纳入统一 SGD 联合训练，或扩展到多目标、多智能体，或引入**层次交互记忆网络**（Gordon 等人 [141]），或用**神经程序合成 + 蒙特卡洛树搜索（MCTS）** 结合知识表和 3D 场景图来规划下一步（Tan 等人 [144]）。
- **LLM/VLM 方法**：如 OpenEQA 用 Blind LLM、苏格拉底式 LLM（基于语言描述/场景图）、VLM 处理多帧；部分工作用**前沿探索（FBE）** 识别待探索区域、构建语义地图，并用共形预测或图文匹配提前结束探索以避免过度探索；Patel 等人 [156] 用多个 LLM 智能体独立回答「是/否」，再训练一个**中央答案模型**聚合出稳健答案。

3) 局限性

- **数据集**：构建数据集耗费大量人力，大规模数据集仍然很少，且各数据集的评估指标不统一，难以公平比较；
- **模型**：即便有 LLM 加持，性能仍远低于人类水平。未来需更有效地存储智能体探索到的环境信息、引导其基于环境记忆与问题规划动作，并增强动作的可解释性。

B. 具身抓取（Embodied Grasping）

具身交互不仅包括问答，还包括基于人类指令**抓取、放置物体**等任务。具身抓取将传统运动学方法 [157][158] 与 LLM、视觉语言模型等大模型结合，实现多感官感知与推理（见图 8）。

1) 数据集（见表 VII）

传统抓取数据集通常包含基于图像（RGB、深度）、点云或 3D 场景的标注抓取数据，提供符合运动学的稳定抓取标注（4-DOF 或 6-DOF），如 **Cornell、Jacquard、6-DOF GraspNet、ACRONYM、MultiGripperGrasp、OCID-Grasp**。但它们缺乏语义信息。随着多模态大模型兴起，这些数据集被扩展重建为**语义抓取数据集**（如 **OCID-VLG、ReasoningGrasp、CapGrasp**），把语言、视觉与抓取关联起来。

2) 语言引导抓取（Language-guided Grasping）

语言引导抓取的语义可来自两类指令：

- **显式指令**：明确指定要抓物体的类别（如「抓那个香蕉/苹果」）；
- **隐式指令**：需要推理才能确定要抓的物体或部位，涉及**空间推理**和**逻辑推理**：
- **空间推理**：「抓棕色纸巾盒**右边**的键盘」——需理解物体空间布局；
- **逻辑推理**：「我渴了，能给我点喝的吗？」——需推断人类意图，递上水杯或饮料，且要保证液体不洒，从而生成合理抓取姿态。

3) 端到端方法

- **CLIPORT**：语言条件的模仿学习智能体，把视觉语言预训练模型 CLIP 与 Transporter Net 结合，构成端到端双流架构；
- **CROG**：基于 OCID 数据集提出视觉–语言–抓取数据集和端到端基线，直接从图文对学习抓取合成；
- **Reasoning Grasping**：基于 GraspNet–1 Billion 提出第一个推理抓取基准数据集和端到端推理抓取模型，融合多模态 LLM 与视觉抓取框架；
- **SemGrasp**：基于语义的抓取生成方法，把语义信息融入抓取表征，用离散表征对齐抓取空间与语义空间，生成灵巧手抓取姿态。

4) 模块化方法

- **F3RM**：把 CLIP 的文本–图像先验提升到 3D 空间，先做语言定位再生成抓取，能泛化到未见表达和新物体类别；
- **GaussianGrasper**：用 3D 高斯场实现语言引导抓取——先建 3D 高斯场，再特征蒸馏、基于语言定位，最后用 SOTA 预训练抓取网络生成抓取姿态。

小结：这些方法通过端到端和模块化框架推进了语言引导抓取，提升了机器人在家居服务和工业制造中的智能与实用性。但当前方法仍依赖大量数据、泛化性差。未来研究目标是增强智能体通用性，让机器人理解复杂语义、抓取各类未见物体、处理复杂任务。

VI. 具身智能体

智能体（agent）被定义为**能感知环境、并采取行动以达成特定目标的自主实体**。多模态大模型（MLMs）的进展进一步拓展了智能体在实际场景中的应用。当这些基于 MLM 的智能体被「具身」到物理实体中时，它们就能把能力从虚拟空间有效迁移到物理世界，从而成为**具身智能体** [172]。

为了让具身智能体在信息丰富、复杂的真实世界中运作，它们发展出强大的多模态感知、交互和规划能力（见图 9）。完成一个任务，具身智能体通常经历两个过程：

1. **高层「具身任务规划」**：把抽象复杂的任务分解为具体子任务；
2. **低层「具身动作规划」**：利用具身感知与具身交互模型（或基础模型的策略函数）逐步实现这些子任务。

值得注意：任务规划是「先想后做」，通常在**网络空间**进行；而动作规划必须考虑与环境的有效交互，并把信息反馈给任务规划器以调整规划。因此，具身智能体从网络空间到物理世界的**对齐与泛化**至关重要。

A. 具身任务规划（Embodied Task Planning）

传统具身任务规划通常基于显式规则和逻辑推理，如 PDDL 符号规划、MCTS、A* 搜索。但这些方法依赖预定义规则、约束和启发式，过于僵硬，难以适应动态或不可预见的变化。随着 LLM 的普及，许多工作尝试用 LLM 规划、或将传统方法与 LLM 结合，利用其丰富的世界知识进行推理规划，无需手工定义，大大增强了泛化能力。

1) 利用 LLM 涌现能力的规划

在自然语言模型规模化之前，任务规划器是通过在 Alfred、Alfworld 等数据集上训练 BERT 类模型实现的（如 FILM），但受限于训练集样本、无法有效对齐物理世界。如今，得益于 LLM 的**涌现能力**，它们能利用内部世界知识和**思维链（Chain-of-Thought）推理**分解抽象任务：

- **Translated LM、Inner Monologue**：无需额外训练，用内部逻辑和知识系统分解复杂任务；
- **ReAd**：多智能体协作框架，通过不同提示高效自我精炼计划；
- **技能记忆库**：把过去成功案例抽象为一系列技能存于记忆库，推理时参考以提升规划成功率；
- **代码作为推理媒介**：用可用 API 库生成代码形式的任务规划；
- **多轮推理纠正幻觉**：如 Socratic Models、Socratic Planner 用苏格拉底式提问得到可靠规划。

然而执行中仍可能失败——往往因规划器未充分考虑真实环境的复杂性和任务执行的难度 [180][189]。由于缺乏视觉信息，规划的子任务可能偏离实际场景。因此，**必须把视觉信息融入规划、或在执行中重规划（replan）**，这能显著提升任务规划的准确性和可行性。

2) 利用具身感知模型视觉信息的规划

在此过程中，视觉输入提供的物体标签、位置或描述，能为 LLM 的任务分解和执行提供关键参考：

- 部分工作用**物体检测器**在执行中查询环境中的物体，反馈给 LLM 以修改当前计划中的不合理步骤 [187][189][190]；
- **RoboGPT**：考虑同一任务中相似物体的不同名称，进一步提升重规划的可行性；
- **SayPlan**：用层次化 **3D 场景图**表示环境，有效缓解大规模、多楼层、多房间场景下的任务规划挑战；
- **ConceptGraphs**：同样采用 3D 场景图，但提供更详细的开放世界物体检测，并以**代码形式**呈现任务规划，更高效、更适合复杂任务。

但有限的视觉信息仍可能导致智能体对环境理解不足。LLM 即便有视觉线索，也常无法捕捉环境的复杂性和动态变化。例如，如果毛巾被锁在浴室柜子里，智能体可能反复搜索浴室而不考虑这种可能 [8]。因此需要更鲁棒的算法整合多感官数据，并利用历史数据与上下文推理（即使视觉信息有限）辅助做出合理判断。

3) 利用 VLM 的规划

相比用外部视觉模型把环境信息转成文本，**VLM 能在潜空间捕捉视觉细节**，尤其是难以用物体标签表示的上下文信息。VLM 能辨别视觉现象背后的规则——例如，即使环境中看不到毛巾，也能推断「毛巾可能收在柜子里」。这在本质上展示了抽象的视觉特征与结构化的文本特征如何在潜空间中更有效地对齐：

- **EmbodiedGPT**：用 Embodied-Former 模块对齐具身、视觉、文本信息；
- **LEO**：把 2D 自我中心图像和 3D 场景编码为视觉 token，有效感知 3D 世界信息；
- **EIF-Unknow**：用从体素特征提取的语义特征图作为视觉 token，与文本 token 一起输入训练好的 LLaVA 做任务规划；
- **VLA 模型**：如 RT 系列 [2][9]、PaLM-E、Matcha，用大规模数据训练，实现具身场景中视觉与文本特征的对齐。

关键点：任务规划只是智能体完成指令任务的第一步，后续的**动作规划**才决定任务能否真正完成。在 RoboGPT 的实验中，任务规划准确率高达 96%，但总任务完成率仅 60%——瓶颈在于低层规划器的性能。因此，具身智能体能否从「想象如何完成任务」的网络空间，跨越到「与环境交互并完成任务」的物理世界，**关键取决于有效的动作规划**。

B. 具身动作规划（Embodied Action Planning）

动作规划必须解决任务规划子任务粒度不足所带来的现实不确定性。它可以通过两种方式实现：**1) 用预训练具身模型通过 API 完成子任务**，或 **2) 利用 VLA 模型的能力**。动作规划的结果会反馈给任务规划以作精炼。

1) 利用 API 的动作执行

常见做法是把训练好的策略模型定义提供给 LLM，让它理解并有效调用：

- 通过生成代码，LLM 把工具抽象成**函数库**，更好处理子任务；
- **Reflexion**：在执行中调整这些工具以提升泛化；
- **DEPS**：让 LLM 通过零样本学习组合各种技能。

这种**层次化规划范式**将高层任务规划与具体动作执行分离，模块化设计支持独立开发、测试和优化，灵活性和可维护性强。但它依赖外部策略模型，可能引入延迟、影响性能，因此策略模型的质量对整体智能体效果至关重要。

2) 利用 VLA 模型的动作执行

与上述「规划与执行分离」不同，这种范式让任务规划与动作执行在**同一系统**内完成，减少了通信延迟，提升了响应速度和效率。在 VLA 模型中，感知、决策、执行模块的紧密集成使系统能更高效地处理复杂任务、适应动态环境变化，并支持实时反馈，让智能体自我调整策略，增强任务执行的鲁棒性和适应性 [10][193][202]。

但这种范式无疑更复杂、成本更高，尤其在处理复杂或长期任务时。此外，一个关键问题是：**没有具身世界模型的动作规划器，仅凭 LLM 的内部知识无法模拟物理规律**——这一局限阻碍了智能体在物理世界准确有效地完成任务，阻碍了从网络空间到物理世界的无缝迁移。

3) 多样化环境中的可扩展性

具身智能体的可扩展性，是指在更大、更多样的环境中，通过鲁棒感知、高效决策和资源优化来适应日益增长的复杂性。策略包括**层次化 SLAM 建图、多模态感知、节能边缘计算**；通过**多智能体系统和去中心化通信**增强协作可扩展性；泛化能力则依赖**领域适应（domain adaptation）** 以在新环境中运作。

VII. 仿真到真实迁移（Sim-to-Real Adaptation）

具身 AI 中的「仿真到真实迁移」，是指把在仿真环境（网络空间）中学习到的能力或行为，迁移到真实世界场景（物理世界）的过程。它涉及**验证并改进在仿真中开发的算法、模型和控制策略**，确保它们在物理环境中稳健、可靠地运行。实现 sim-to-real 迁移有三大要素：**具身世界模型、数据收集与训练方法、具身控制算法**。

A. 具身世界模型（Embodied World Model）

Sim-to-Real 需要创建与真实环境高度相似的、基于仿真的世界模型。这些模型通过**预测下一状态来做决策**，是在物理世界数据上从头训练的——不同于 VLA 模型（在大规模数据上预训练、再用真实数据微调）。世界模型适合**结构化任务**（如自动驾驶、物体分拣），但不太适合非结构化、复杂的任务。

学习世界模型是物理仿真领域很有前景的方向。相比传统仿真方法，它的优势包括：能在信息不完整时对交互进行推理、满足实时计算要求、随时间提升预测精度。这种预测能力至关重要，能让机器人具备在人类世界中运作所需的**物理直觉**。按学习流程，可分为三类（见图 10）：

1) 基于生成的方法（Generation-based）

随着模型和数据规模的增大，生成模型已能理解和生成符合物理规律的图像（World Models）、视频（Sora、Pandora）、点云（3D-VLA）等数据。这说明生成模型能**内化世界知识**——在见过大规模数据后，它们不仅捕捉统计特性，还能通过内在结构模拟物理和因果关系，因此表现出世界模型的特征。这些内嵌的世界知识可用于提升其他模型的泛化性、鲁棒性和预测精度。

局限：面对有偏的数据分布或训练不足时，可能产生不准确或失真的输出；训练需大量算力和时间；缺乏可解释性。

2) 基于预测的方法（Prediction-based）

这类世界模型通过构建和利用内部表征来预测和理解环境，即在**潜空间**中基于给定条件重建特征，捕捉更深层语义和世界知识。它将输入映射到潜空间并在此空间运作，提取高层语义信息，让机器人感知世界环境的本质表征（如 I-JEPA、MC-JEPA、A-JEPA、Point-JEPA、IWM），并更准确地执行具身下游任务（如 iVideoGPT、IRASim、STP、MuDreamer）。

潜特征不同于像素级信息，能抽象并解耦各种知识，使模型更有效地处理复杂任务和场景、增强泛化。例如在时空建模中，世界模型通过综合物体当前状态、交互性质和内部知识来预测交互后的状态。

局限：处理未见过的环境和条件时可能出现不稳定；潜空间中解耦的世界知识可能带来可解释性问题。

3) 知识驱动的方法（Knowledge-driven）

知识驱动的世界模型把**人工构造的知识注入模型**，赋予其世界知识：

- **real2sim2real**：用真实世界知识构建物理合规的仿真器，再训练机器人，增强鲁棒性和泛化；
- 把人工构造的常识或物理合规知识应用于生成模型/仿真器（如 ElastoGen、One-2-3-45、PLoT），对模型施加更物理准确的约束，提升生成任务的可靠性和可解释性；
- 结合人工物理规则与 LLM/MLM（如 Holodeck、LEGENT、GRUtopia），通过自动空间布局优化生成多样、语义丰富的场景，在新颖多样的环境中训练通用具身智能体。

4) 局限性

当前世界模型的局限包括：难以处理真实世界环境的复杂性与多变性（高维感知输入、动态随机元素、长期依赖）；许多模型在未见场景上泛化困难，常需大量训练数据和算力；sim-to-real 迁移仍有问题，因为仿真环境无法完全捕捉真实世界的物理和噪声。解决方向包括：集成更逼真的仿真器、纳入多模态感知输入、采用层次化/模块化架构、提升数据效率、改进迁移学习技术、引入真实世界先验。近期 NVIDIA 提出 **Cosmos 平台**（含自回归和扩散模型，用于 Text-to-World、Video-to-World 生成），加速物理 AI 系统的发展，为如何构建具身世界模型提供了启发。

B. 数据收集与训练（Data Collection and Training）

对 sim-to-real 迁移而言，高质量数据至关重要。传统数据收集依赖昂贵设备和精确操作，耗时费力。最近出现了一些高效低成本的高质量示范数据收集与训练方法。

1) 真实世界数据（Real-World Data）

用丰富数据集训练大容量模型已取得巨大成功，在机器人领域同样前景广阔——大规模多样数据集能增强泛化和适应性：

- **Open X-Embodiment**：来自 22 个机器人、527 项技能、160,266 个家庭场景任务的数据；
- **UMI**：用手持夹爪采集动态双手操作数据的框架；
- **Mobile ALOHA**：支持全身移动操作任务的数据采集；

- **人机协作**：结合人类输入与智能体精炼过程，提升数据质量和效率。

2) 仿真数据（Simulated Data）

真实环境数据采集资源密集、耗时，因此基于仿真的数据采集成为有吸引力的替代方案。仿真环境支持自动化、高效的数据采集。例如 CLIPORT 和 Transporter Networks 用 PyBullet 仿真器数据训练并成功迁移到真实应用；GAPartNet 开发了带部件级标注的大规模数据集；SemGrasp 创建了 CapGrasp 数据集用于语义丰富的灵巧手抓取。

3) Sim-to-Real 的五个范式（见图 11）

- **Real2Sim2real**：在「数字孪生」仿真中用强化学习开发策略，再迁移到真实世界；
- **TRANSIC**：通过实时人类干预和基于纠正行为的残差策略训练来缩小 sim-to-real 差距；
- **域随机化（Domain Randomization）**：变化仿真参数以覆盖真实世界条件，增强模型泛化；
- **系统辨识（System Identification）**：创建真实场景的精确仿真，确保仿真到现实的平滑过渡；
- **Lang4sim2real**：用自然语言描述桥接 sim-to-real 差距，通过跨域图像表征提升泛化。

4) ARIO（All Robots In One，万机合一）

尽管 Open X-Embodiment 等预训练数据集结构看似统一，仍有几个关键问题未解决：**缺乏综合感官模态**（尚无数据集同时整合图像、3D 视觉、文本、触觉和听觉输入）；多机器人数据集**格式不统一**；不同机器人平台的**控制对象表示不兼容**；**数据量不足**难以支持大规模预训练；以及**缺少仿真与真实结合的数据**（这对解决 sim-to-real 差距至关重要）。

为此，作者提出 **ARIO 标准**——一种新的数据集标准，统一格式记录不同形态机器人的控制与运动数据，确保精确时间戳，从而让用户高效训练高性能、可泛化的具身 AI 模型。基于该标准进一步构建了统一的大规模 **ARIO 数据集**，包含约 **300 万个片段**，来自 **258 个系列**和 **321,064 个任务**（见图 12）。

5) 具身 AI 系统的真实世界部署

具身 AI 系统已在多个场景取得显著进展：医疗（达芬奇手术系统、Moxi）、物流（Amazon Robotics、波士顿动力 Stretch）、制造（Fanuc、ABB）。但 sim-to-real 迁移仍面临重大挑战：仿真与真实数据分布之间的**域差距**、动态真实交互的复杂性、以及训练数据多样性有限——模型常过拟合仿真、难以应对真实传感器噪声、无法处理意外事件。

VIII. 挑战与未来方向

尽管具身 AI 进展迅速，它仍面临若干挑战，并蕴含着令人兴奋的未来方向：

- **高质量机器人数据集**：获取足够的真实机器人数据仍是重大挑战，采集耗时耗资源；仅靠仿真数据又会加剧 sim-to-real 差距。需要机构间广泛协作、开发更逼真高效的仿真器，并构建大规模数据集（用高质量仿真数据辅助真实数据）。
- **长程任务执行（Long-Horizon Task Execution）**：如「打扫厨房」这类指令，涉及重新摆放物体、扫地、擦桌等一长串长时间跨度的低层动作。当前高层任务规划器虽初获成功，但在多样场景中仍显不足。需要配备鲁棒感知能力和大量常识知识的高效规划器；可通过「轻量监控模块（高频监控）+ 两个适配器（低频的子任务与路径适配推理）」来平衡规划复杂度与实时适应性。
- **因果推理（Causal Reasoning）**：现有数据驱动的具身智能体基于数据相关性做决策，并不真正理解知识、行为与环境之间的因果联系，导致策略有偏。具身智能体应由世界知识驱动、具备自主因果推理能力——通过交互理解世界、通过溯因推理学习其运作规律，从而提升在复杂真实环境中的适应性、决策可靠性和泛化能力。具身任务还需建立跨模态的时空因果关系，并理解物体「可供性」（affordance）。
- **统一评估基准（Unified Evaluation Benchmark）**：现有低层控制策略的基准众多，但评估的技能差异很大，且物体和场景受仿真器限制。更理想的做法是**同时评估高层任务规划器和低层控制策略**，测长程任务的执行成功率，而非孤立地评估规划器。
- **安全与隐私（Security and Privacy）**：具身智能体部署在敏感或私密空间时面临重大安全挑战。它们依赖 LLM 决策，引入了新的漏洞——LLM 易受**后门攻击**（词注入、场景操纵、知识注入），可能导致自动驾驶加速撞向障碍物、机器人执行危险动作等严重后果。需评估潜在攻击向量、开发更鲁棒的防御，并用安全提示、状态管理和安全验证机制增强安全性与鲁棒性。

IX. 结论

具身 AI 让智能体能够从网络空间和物理世界感知、认知并交互各种物体，对实现 AGI 具有重大意义。本综述全面回顾了具身机器人、仿真器、四类代表性具身任务（视觉主动感知、具身交互、具身智能体、仿真到真实迁移）以及未来研究方向。对具身机器人、仿真器、数据集和方法所作的对比总结，清晰地呈现了具身 AI 的近期发展图景，将极大裨益于这一新兴而有前景方向的未来研究。

> **（全文正文翻译完）** 参考文献部分（约 150 篇）保留英文，见原 PDF 第 16–21 页。